

Rapport Technique : Prétraitement des Données et Rééquilibrage par SMOTE

1. Introduction

Ce document décrit de manière rigoureuse et structurée le pipeline de préparation des données pour un modèle de prédiction de pannes électriques. L'objectif est de construire deux datasets supervisés permettant :

- l'anticipation des pannes (variable cible : `pre_fault`)
- la confirmation des pannes (variable cible : `outage`)

Le traitement respecte les contraintes fortes des séries temporelles et évite toute fuite d'information (data leakage).

2. Description du dataset original

Le dataset initial est un fichier CSV horodaté contenant des mesures électriques collectées toutes les 2 secondes.

2.1 Variables principales

- `timestamp` : horodatage
- `voltage_v` : tension (V)
- `frequency_hz` : fréquence (Hz)
- `power_w` : puissance (W)
- `thd_percent` : distorsion harmonique (%)

2.2 Variables cibles

- `pre_fault` : signal précurseur de panne
 - `outage` : coupure électrique
 - `micro_outage` : microcoupure
-

3. Contraintes des séries temporelles

Contrairement aux données i.i.d., les séries temporelles présentent :

- une dépendance temporelle forte
- un ordre chronologique strict
- un risque élevé de fuite d'information

3.1 Problème classique

Un découpage aléatoire entraînerait :

- une contamination du test par le futur
- une surestimation des performances

3.2 Solution adoptée

Un découpage **temporel strict** est appliqué :

$$Train = [t_0, t_{80\%}], \quad Test = [t_{80\%}, t_{100\%}]$$

4. Feature Engineering temporel

Afin de capturer la dynamique du système électrique, des variables dérivées sont construites.

4.1 Variables retardées (lag features)

Pour chaque variable physique :

$$X_{t-1}, X_{t-2}, \dots, X_{t-5}$$

Ces variables permettent au modèle d'apprendre les tendances récentes.

4.2 Statistiques glissantes

Deux statistiques sont ajoutées :

- moyenne glissante
- écart-type glissant

$$\mu_t = \frac{1}{W} \sum_{i=1}^W X_{t-i}$$
$$\sigma_t = \sqrt{\frac{1}{W} \sum_{i=1}^W (X_{t-i} - \mu_t)^2}$$

avec $W = 10$.

4.3 Propriété causale

Toutes les features utilisent uniquement le passé :

$$X_t^{feature} = f(X_{t-1}, X_{t-2}, \dots)$$

Cela garantit l'absence de fuite d'information.

5. Nettoyage des données

L'introduction de décalages (lag) génère des valeurs manquantes en début de série.

Solution : suppression des lignes contenant des NaN.

6. Construction des datasets

6.1 Séparation des variables

Les variables explicatives sont définies comme :

$$FEATURES = Dataset \setminus \{timestamp, cycle, targets\}$$

6.2 Deux problèmes supervisés

Dataset A : anticipation

$$y_A = pre_fault$$

Dataset B : confirmation

$$y_B = outage$$

7. Déséquilibre des classes

Les distributions observées sont fortement déséquilibrées :

- `pre_fault` : événement rare ($\approx 0.1\%$)
- `outage` : déséquilibre modéré

Cela rend l'apprentissage difficile.

8. Principe de SMOTE

SMOTE (Synthetic Minority Over-sampling Technique) génère des exemples synthétiques de la classe minoritaire.

8.1 Formulation

Pour un point minoritaire x_i et un voisin x_j :

$$x_{new} = x_i + \lambda(x_j - x_i), \quad \lambda \in [0, 1]$$

8.2 Intuition

- interpolation dans l'espace des features
 - enrichissement de la distribution minoritaire
-

9. Particularité de SMOTE pour les séries temporelles

SMOTE n'est pas conçu pour les séries temporelles.

9.1 Risques

- rupture de la cohérence temporelle
- création de séquences irréalistes

9.2 Mesures prises

1. SMOTE appliqué uniquement sur le train
 2. utilisation de features déjà agrégées (lags)
 3. pas d'utilisation sur le test
 4. ratios contrôlés (pas d'équilibrage total)
-

10. Normalisation des données

SMOTE étant basé sur des distances, les données sont normalisées :

$$X' = \frac{X - \mu}{\sigma}$$

Cette étape est réalisée avant SMOTE.

11. Application de SMOTE

11.1 Dataset A (pre_fault)

- déséquilibre extrême
- stratégie : ratio 1:10
- k_neighbors = 3

11.2 Dataset B (outage)

- déséquilibre modéré
 - stratégie : ratio 1:3
 - k_neighbors = 5
-

12. Construction finale des datasets

12.1 Train

- features normalisées
- données rééquilibrées avec SMOTE

12.2 Test

- features normalisées
 - données non modifiées (distribution réelle)
-

13. Export des données

Quatre fichiers sont générés :

- train_pre_fault.csv
- test_pre_fault.csv
- train_outage.csv
- test_outage.csv

Chaque fichier contient :

- les variables explicatives
 - une colonne `target`
-

14. Conclusion

Le pipeline proposé respecte les bonnes pratiques en apprentissage sur séries temporelles :

- respect de la causalité
- absence de fuite d'information
- gestion du déséquilibre
- préparation adaptée aux modèles ML

Ce travail constitue une base robuste pour l'entraînement de modèles de classification avancés.